

LSTMs for Human Activity Projesi

Literatür Taraması

İnsan Aktivite Tanıma (Human Activity Recognition - HAR), son yıllarda mobil cihazlar ve giyilebilir teknolojilerin gelişmesiyle birlikte giderek daha fazla önem kazanan bir araştırma alanı olmuştur. Akıllı telefonlardaki ivmeölçer ve jiroskop sensörlerinden elde edilen veriler, bireylerin gerçekleştirdiği fiziksel aktivitelerin otomatik olarak sınıflandırılmasını mümkün kılmaktadır. Bu tür sistemler, sağlık takibi, spor analizi, rehabilitasyon, akıllı ev sistemleri ve güvenlik gibi çeşitli uygulama alanlarında kullanılmaktadır. Geleneksel makine öğrenmesi tabanlı yöntemler, insan aktivitelerinin doğru şekilde sınıflandırılabilmesi için kapsamlı özellik mühendisliği gerektirmektedir. Bu yöntemler genellikle sinyal işleme teknikleriyle belirli özniteliklerin çıkarılmasını ve daha sonra bu özniteliklerin bir sınıflandırıcıya beslenmesini içerir. Ancak bu süreç, karmaşık ve zaman alıcıdır. Derin öğrenme yaklaşımlarının gelişimi ile birlikte, Recurrent Neural Networks (RNN) ve özellikle Long Short-Term Memory (LSTM) hücreleri, zaman serisi verilerini işleyebilme yetenekleri sayesinde bu alanda güçlü bir alternatif haline gelmiştir.

Bu çalışmada, LSTM tabanlı bir RNN modeli kullanılarak yürüme, merdiven çıkma, merdiven inme, oturma, ayakta durma ve yatma olmak üzere altı farklı fiziksel aktivite sınıflandırılacaktır. LSTM'nin en büyük avantajı, veri ön işleme ihtiyacını en aza indirerek doğrudan ham sensör verileriyle çalışabilmesi ve zaman içindeki bağımlılıkları öğrenerek daha doğru tahminler yapabilmesidir. Bu bağlamda, çalışmada Google'ın tensorflow kütüphanesi kullanılarak HAR veri seti üzerinde LSTM tabanlı bir model eğitilecek ve modelin doğruluk performansı değerlendirilecektir. LSTM'nin, geleneksel makine öğrenmesi yöntemlerine kıyasla daha az ön işleme gerektirdiği ve daha yüksek başarı sağladığı test edilerek, derin öğrenmenin bu alandaki potansiyeli ortaya konulacaktır.

Son yıllarda, derin öğrenme modellerinin gelişimi ile birlikte insan aktivitelerinin daha yüksek doğrulukla tanınması mümkün hale gelmiştir. Akıllı telefonların yaygınlaşması ve üzerlerinde bulunan sensörlerin gelişmesi sayesinde, hareket verileri üç boyutlu olarak (X-Y-Z eksenlerinde) ham formatta toplanabilmektedir. Bu çalışmada, insan aktivitelerinin sınıflandırılması için açık kaynaklı Wireless Sensor Data Mining (WISDM) veri seti kullanılmıştır. Veri seti, yürüme, koşma, oturma, ayakta durma, merdiven çıkma ve merdiven inme olmak üzere altı farklı aktiviteyi içermektedir. Her bir aktiviteye ait veriler, sensörlerden elde edilen X, Y ve Z eksenlerindeki hareket değerleri ile temsil edilmektedir. (ALBABA, QASSAB and YILMAZ, 2020)

HAR-P adını verdiğimiz veri setinde yürüme, koşma, yazı yazma, merdiven inme, merdiven çıkma, oturma, ayakta durma ve namaz kılma gibi 8 aktivite için doğrusal hızlanma, ivme, manyetik alan ve jiroskop sensör verileri yer almaktadır. HAR-P veri seti için akıllı saat ile 15-60 yaş arası 50 erkek gönüllüden veri toplanmıştır. HAR-P veri kümesinde LSTM, ConvLSTM ve CNNLSTM modellerinin sınıflandırma başarısı karşılaştırılmıştır. Ortalama en yüksek başarı oranı olan %91'e doğrusal hızlanma sensörü ile LSTM yöntemi ve ivme sensörü ile ConvLSTM modelinde ulaşılırken, en düşük ortalama başarı oranı olan %83,6'a jiroskop sensörü ve ConvLSTM yöntemi ile ulaşılmıştır. (Vurgun and Kiran, 2024)

İnsan aktivitelerinin anlık olarak sınıflandırılması, sağlık, fizik tedavi ve akıllı ev sistemleri gibi birçok alanda önemli bir rol oynamaktadır. Bu çalışmada, akıllı telefonlardaki ivmeölçer ve jiroskop sensörlerinden elde edilen veri kümesi kullanılarak insan aktiviteleri sınıflandırılmıştır. Literatürdeki çalışmalar, yapay sinir ağları ile zaman serisi verilerini işlerken öznitelikler arasındaki ilişkileri tam olarak çözmemektedir. Bu nedenle, Uzun-Kısa Süreli Bellek modeli kullanılarak aktivite tanıma gerçekleştirilmiş ve zaman serisi verileri daha verimli bir şekilde işlenmiştir. Farklı ağ parametreleri ve katman konfigürasyonlarıyla yapılan deneyler sonucunda, %86 ile %93 arasında değişen yüksek doğruluk oranları elde edilmiştir. Bu sonuçlar, LSTM tabanlı modellerin insan aktivite tanımada güçlü bir yöntem olduğunu ortaya koymaktadır.(Metin and Karasulu, 2019)

İnsan aktivite tanıma (HAR) sistemleri, video gözetimi, ses takibi, görüntü işleme ve sensör tabanlı hareket algılama gibi farklı yöntemlerle gerçekleştirilmektedir. Bu çalışmada, sensör verileri kullanılarak aktiviteler sınıflandırılmış ve KNN, Random Forest, Decision Tree, MLP ve Naive Bayes algoritmaları uygulanmıştır. KNN, en yakın komşu tabanlı sınıflandırma sağlarken, Random Forest çok sayıda karar ağacını birleştirerek tahmin yapmaktadır. Decision Tree veri dallanma yapılarıyla karar kuralları oluştururken, MLP, çok katmanlı sinir ağı yapısıyla öğrenme gerçekleştirmektedir. Naive Bayes ise, olasılık hesaplamalarıyla hızlı ve etkili sınıflandırma sunmaktadır. Literatürde, HAR için farklı veri toplama yöntemleri ve makine öğrenmesi modellerinin etkinliği incelenmiştir. Örneğin, bazı çalışmalar giyilebilir IoT cihazlarıyla veri toplarken, diğerleri derin öğrenme ve genetik algoritmalar gibi optimizasyon tekniklerini kullanarak modelleri geliştirmiştir. Yapılan araştırmalar, sensör tabanlı HAR sistemlerinin mobil cihazlar ve IoT teknolojileriyle birleşerek daha hassas ve verimli hale geleceğini göstermektedir.(KALKAN and AR, 2023)

Günümüzde sensör verilerinin işlenmesine dayalı çalışmalar, insan aktivitelerinin tespiti ve sınıflandırılması gibi alanlarda yaygın olarak kullanılmaktadır. Derin öğrenme modellerinin ham veriden otomatik olarak öznitelik öğrenebilme yeteneği, bu sistemlerin doğruluğunu artırarak popüler hale getirmiştir. Bu çalışmada, WISDM, UCI ve yeni oluşturulan İGAV veri kümesi kullanılarak, üç eksenli jiroskop ve ivmeölçer sensörlerinden toplanan verilerle insan aktivitelerinin sınıflandırılması gerçekleştirilmiştir. Veriler, 10 gönüllüden (5 erkek, 5 kadın) gerçek zamanlı olarak doğal ortamlarda toplanmış ve laboratuvar koşullarının sınırlamalarından bağımsız bir yaklaşım benimsenmiştir. Deneylerde beş farklı derin öğrenme modeli test edilmiş ve kullanıcıların ağ parametrelerini belirleyerek deney yapabilmesine olanak sağlayan özgün bir yazılım arayüzü geliştirilmiştir. Sonuçlara göre, WISDM veri kümesi üzerinde bir boyutlu ESA derin ağ mimarisi ile %99,09 doğruluk, İGAV veri kümesi üzerinde çift yönlü UKSB ağı ile %97,85 doğruluk elde edilmiştir. Bu bulgular, derin öğrenme tabanlı yöntemlerin yüksek doğruluk oranlarıyla insan aktivite tanımada başarılı olduğunu göstermektedir. Çalışma, İGAV veri kümesini literatüre kazandırarak yeni araştırmalar için genişletilebilir bir kaynak sunmakta ve farklı model kombinasyonları ile gelecekte geliştirilmeye açık bir yapı ortaya koymaktadır.(Metin and Karasulu, 2021)

ALBABA, M., QASSAB, A. and YILMAZ, A. (2020) 'Human activity recognition and classification using of convolutional neural networks and recurrent neural networks', *International Journal of Applied Mathematics Electronics and Computers*, 8, pp. 185–189. Available at: <https://doi.org/10.18100/ijamec.803105>.

KALKAN, M. and AR, Y. (2023) 'Classification of human activities by smart device measurements', *Communications Faculty of Sciences University of Ankara Series A2-A3 Physical Sciences and Engineering*, 65, pp. 166–178. Available at: <https://doi.org/10.33769/aupse.1306885>.

Metin, İ.A. and Karasulu, B. (2021) ‘A novel dataset of human daily activities: Its benchmarking results for classification performance via using deep learning techniques’, *Journal of the Faculty of Engineering and Architecture of Gazi University*, 36, pp. 759–777. Available at: <https://doi.org/10.17341/gazimmfd.772849>.

Metin, İ.A. and Karasulu, B. (2019) *İnsan Aktivitelerinin Sınıflandırılmasında Tekrarlayan Sinir Ağı Kullanan Derin Öğrenme Tabanlı Yaklaşım*, <https://dergipark.org.tr/tr/pub/veri/issue/51241/641026>.

Vurgun, Y. and Kiran, M.S. (2024) ‘İnsan aktivite tanınması için yeni bir veri kümesi ve derin öğrenme modelleri ile sınıflandırılması’, *Journal of the Faculty of Engineering and Architecture of Gazi University*, 40, pp. 653–671. Available at: <https://doi.org/10.17341/gazimmfd.1325926>.